BIG DATA

CURS 5

Apache Spark SQL

Introducere

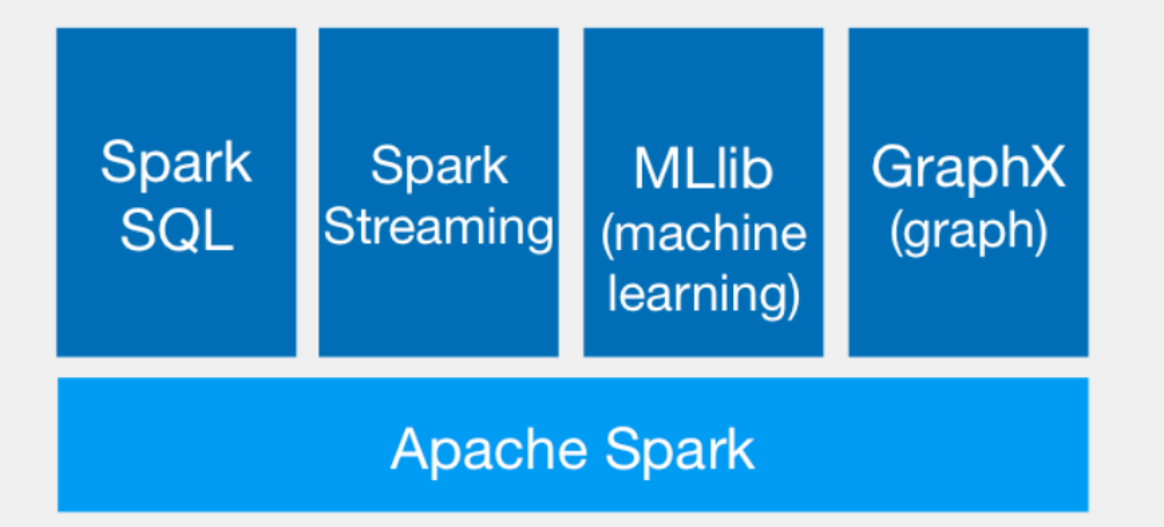

SparkSession vs Spark/SQLContext

- În exemplele practice din cursul anterior am inițializat un obiect *SparkContext*, iar apoi (pe baza acestuia) un obiect *SQLContext*
- Putem avea un punct de intrare unificat (Spark >= 2.0): *SparkSession*
- *SparkSession* oferă un mod mai simplu (mai puține obiecte construite) de a interacționa cu diferite funcționalități Spark
  - Încapsulează Spark context, Hive context, SQL context
- Anterior versiunii 2.0 *SparkContext* a fost singurul punct de intrare pentru orice aplicație Spark, fiind folosit pentru a accesa restul funcționalităților / componentelor Spark.

SparkSession vs Spark/SQLContext

- Cu ajutorul *SparkContext* putem crea doar RDD-uri
- Erau necesare contexte Spark specifice pentru alte interacțiuni cu Spark: *SQLContext*, *HiveContext*, pentru aplicațiile de *Streaming*.
- *SparkSession* este o combinație a acestor contexte diferite.
  - Intern, *SparkSession* crează un *SparkContext* pentru fiecare operație
  - Toate contextele menționate anterior pot fi accesate folosind obiectul *SparkSession*.
- Alt avantaj al *SparkSession*: în cazul mai multor utilizatori care accesează același *SparkContext*.

Crearea unei sesiuni Spark

```
from pyspark.sql import SparkSession

spark = SparkSession \
    .builder \
    .appName("Spark SQL Test") \
    .config("spark.some.config.option", "some-value") \
    .getOrCreate()
```

Crearea unui *DataFrame*

- În exemplele din cursul 4 am creat *DataFrame*-uri pornind de la RDD-uri
- Alte metode: din sursele de date Spark (fișier *Parquet*, fișier JSON, tabel Hive, JDBC către alte BD, fișier avro, fișiere binare)

Crearea unui *DataFrame*

```
# spark = obiectul SparkSession creat anterior
df = spark.read.json("people.json")
# afișarea DataFrame-ului la consolă
df.show()

+----+-------+
| age|   name|
+----+-------+
|null|Michael|
|  30|   Andy|
|  19| Justin|
+----+-------+
```

Operații pe *DataFrame*-uri

- *DataFrame* = *DataSet* de (obiecte) *Row* în API-urile Java și Scala
- *DataFrame* API oferă un limbaj DSL (*Domain Specific Language*) pentru prelucrarea datelor structurate
- Operațiile pe *DataFrame*-uri -> transformări *untyped*
- Operațiile pe *DataSet*-uri -> transformări *typed* (*DataSet*-urile Java/Scala sunt puternic tipizate)

Operații pe *DataFrame*-uri

- Accesarea unei coloane
  - În Python accesarea unei coloane se poate face:
    - Prin atribut: <data_frame>.<atribut>
    - Prin indexare: <data_frame>['<atribut>']

- Lista completă a operațiilor: https://spark.apache.org/docs/latest/api/python/reference/pyspark.sql.html#dataframe-apis
- Funcții utile (prelucrare șiruri de caractere, date calendaristice, operații aritmetice): https://spark.apache.org/docs/latest/api/python/reference/pyspark.sql.html#functions

Exemplu

```
#Afisarea schemei (format arbore)
df.printSchema()
```

```
# root
# |-- age: long (nullable = true)
# |-- name: string (nullable = true)
```

```
# Selectarea și afișarea coloanei
"name"
df.select("name").show()
```

```
# +-------+
# |   name|
# +-------+
# |Michael|
# |   Andy|
# | Justin|
# +-------+
```

```
# Selectarea tuturor persoanelor, cu
vârsta mărită cu 1
df.select(df['name'], df['age'] +
1).show()
```

```
# +-------+---------+
# |   name|(age + 1)|
# +-------+---------+
# |Michael|     null|
# |   Andy|       31|
# | Justin|       20|
# +-------+---------+
```

Exemplu

```
# Selectarea persoanelor cu vârsta  >
21
df.filter(df['age'] > 21).show()
```

```
# +---+----+
# |age|name|
# +---+----+
# | 30|Andy|
# +---+----+
```

```
# Numărarea persoanelor după vârstă
df.groupBy("age").count().show()
```

```
# +----+-----+
# | age|count|
# +----+-----+
# |  19|    1|
# |null|    1|
# |  30|    1|
# +----+-----+'
```

Execuția programatică a cererilor SQL

- Funcția *sql* din *SparkSession* permite aplicațiilor să ruleze programatic cereri SQL și să returneze un rezultat de tip *DataFrame*.

```
# Înregistrează obiectul DataFrame ca view SQL temporara
df.createOrReplaceTempView("people")

sqlDF = spark.sql("SELECT * FROM people")
sqlDF.show()
# +----+-------+
# | age|   name|
# +----+-------+
# |null|Michael|
# |  30|   Andy|
# |  19| Justin|
```

Vizualizare temporară globală

- Vizualizările temporare din Spark SQL sunt obiecte la nivel de sesiune – vor dispărea atunci când se încheie sesiunea care le-a creat.
- Vizualizare temporară globală – vizualizare temporară care este partajată între mai multe sesiuni, ce este menținută până când se încheie aplicația Spark.
- Este legată de o bază de date menținută de către sistem (*global_temp*) și trebuie să calificăm numele vizualizării, atunci când o referim, cu numele acestei baze de date.

Vizualizare temporară globală

```
# Înregistrarea DataFrame-ului ca vizualizare temporară globală
df.createGlobalTempView("people")

# Vizualizarea temporară globală se află în global_temp
spark.sql("SELECT * FROM global_temp.people").show()
# +----+-------+
# | age|   name|
# +----+-------+
# |null|Michael|
# |  30|   Andy|
# |  19| Justin|
# +----+-------+

# Vizualizarea temporară globală este disponibilă și în alte sesiuni
spark.newSession().sql("SELECT * FROM global_temp.people").show()
# +----+-------+
# | age|   name|
# +----+-------+
# |null|Michael|
# |  30|   Andy|
# |  19| Justin|
# +----+-------+
```

Interoperabilitatea cu RDD

- Spark SQL suportă două metode diferite pentru convertirea RDD-urilor existente în *Dataset*-uri.
- Prima metodă utilizează reflexia pentru a deduce schema unui RDD ce conţine tipuri specifice de obiecte
  - Această metodă înseamnă cod mai concis şi funcţionează bine atunci când cunoaştem deja schema.
- A doua metodă presupune utilizarea unei interfeţe de programare ce permite construirea unei scheme şi apoi aplicarea acesteia unui RDD existent.
  - Mai mult cod
  - Permite construirea de *Dataset*-uri atunci când coloanele şi tipurile de date ale acestora nu sunt cunoscute până la runtime.

Deducerea schemei utilizând reflexia

- Spark SQL poate converti un RDD de obiecte *Row* într-un *DataFrame*, deducând tipurile de date.
- Obiectele *Row* sunt construite prin transmiterea unei liste de perechi cheie/valoare drept *kwargs* clasei *Row*.
- Cheile acestei liste definesc numele coloanelor tabelului, iar tipurile sunt deduse eșantionând întregul *dataset*, similar inferenței asupra fișierelor JSON.

Deducerea schemei utilizând reflexia

```
from pyspark.sql import Row

sc = spark.sparkContext

# Încarcă fișierul text și convertește fiecare linie într-un Row
lines = sc.textFile("people.txt")
parts = lines.map(lambda l: l.split(","))
people = parts.map(lambda p: Row(name=p[0], age=int(p[1])))

# Deduce schema și înregistrează DataFrame-ul ca tabel
schemaPeople = spark.createDataFrame(people)
schemaPeople.createOrReplaceTempView("people")

# Cererile SQL pot fi executate asupra DataFrame-uriloe care au fost înregistrate ca tabele.
teenagers = spark.sql("SELECT name FROM people WHERE age >= 13 AND age <= 19")

# Rezutatele cererilor SQL sunt obiecte DataFrame.
# rdd returnează conținutul ca obiect :class:`pyspark.RDD` al :class:`Row`.
teenNames = teenagers.rdd.map(lambda p: "Name: " + p.name).collect()
for name in teenNames:
    print(name)
# Name: Justin
```

Specificarea programatică a schemei

- Atunci când un dicționar de *kwargs* nu poate fi definit anterior, un *DataFrame* se poate crea programatic urmând 3 pași:

  1. Crearea unui RDD de tupluri sau a unei liste din RDD-ul original

  2. Crearea schemei reprezentate de un *StructType* corespunzător structurii tuplurilor sau listelor din RDD-ul construit la pasul anterior

  3. Aplicarea schemei asupra RDD-ului prin intermediul metodei *createDataFrame* din *SparkSession*.

Specificarea programatică a schemei

```
# Import tipuri de date
from pyspark.sql.types import StringType, StructType, StructField

sc = spark.sparkContext

# Încărcarea unui fișier text și convertirea fiecărei linii în Row.
lines = sc.textFile("examples/src/main/resources/people.txt")
parts = lines.map(lambda l: l.split(","))
# Fiecare linie este convertită într-un tuplu
people = parts.map(lambda p: (p[0], p[1].strip()))

# Schema este encodată într-un string.
schemaString = "name age"

fields = [StructField(field_name, StringType(), True) for field_name in schemaString.split()]
schema = StructType(fields)

# Aplicarea schemei pe RDD.
schemaPeople = spark.createDataFrame(people, schema)

# Crearea unui view temporar pe baza DataFrame-ului
schemaPeople.createOrReplaceTempView("people")

# SQL poate fi executat pe DataFrame-uri care au fost înregistrate ca tabele.
results = spark.sql("SELECT name FROM people")

results.show()
# +-------+
# |   name|
# +-------+
# |Michael|
# |   Andy|
# | Justin|
# +-------+
```

Funcții scalare

- Sunt funcții ce returnează câte o valoare (singulară) pentru fiecare *Row*
- Spark SQL suportă o diversitate de funcții scalare predefinite: https://spark.apache.org/docs/latest/sql-ref-functions.html#scalar-functions
- De asemenea, suportă funcțiile scalare definite de utilizator (UDF): https://spark.apache.org/docs/latest/sql-ref-functions-udf-scalar.html

Exemplu UDF cu Python

- Demo în Jupyter Lab

Funcții agregat

- Sunt funcții ce returnează o singură valoare pentru un grup de linii (*Row*)
- Funcțiile agregat predefinite suportă tipurile de agregare obișnuite, precum *count*, *countDistinct*, *avg*, *max*, *min*
  - https://spark.apache.org/docs/latest/sql-ref-functions-builtin.html#aggregate-functions
- Utilizatorii pot crea și funcții agregat (UDAF – User Defined Aggreate Functions) în Scala și Java
  - https://spark.apache.org/docs/latest/sql-ref-functions-udf-aggregate.html

Menținerea datelor în memorie (*caching*)

- Spark SQL poate păstra tabelele în *cache* folosind un format columnar. Apelăm:
  - `spark.catalog.cacheTable("tableName")` sau
  - `dataFrame.cache()`
- Apoi, Spark SQL va parcurge doar coloanele necesare și va optimiza compresia astfel încât utilizarea memoriei și a presiunii asupra GC (GC Pressure – Garbage Collector Pressure) să fie minimizate.
- Ștergerea tabelului din memorie:
  - `spark.catalog.uncacheTable("tableName")`

Menținerea datelor în memorie (*caching*)

- Configurarea *caching*-ului *in-memory* se poate realiza cu ajutorul metodei *setConf* asupra *SparkSession* sau prin execuția de comenzi *SET cheie=valoare* folosind SQL
- *spark.sql.inMemoryColumnarStorage.compressed* (implicit *true*) – Spark SQL va selecta automat un codec pentru compresia fiecărei coloane, pe baza statisticilor datelor
- *spark.sql.inMemoryColumnarStorage.batchSize* (implicit 10000) – controlează dimensiunea *batch*-urilor pentru *caching*-ul columnar. Cu cât dimensiunea este mai mare, cu atât este îmbunătățită utilizarea memoriei și compresia, dar apare riscul de erori *OutOfMemory* la *caching-ul* datelor.

Strategii pentru operația de *join*

- Hint-urile pentru strategia de join:
  - *BROADCAST*
  - *MERGE*, *SHUFFLE_HASH* şi *SHUFFLE_REPLICATE_NL (* >= 3.0)
- Aceste *hint*-uri instruiesc Spark să folosească o anumită strategie pe fiecare relație specificată, atunci când are loc operația de *join* a acesteia cu o altă relație.
- *spark.sql.autoBroadcastJoinThreshold* – dimensiunea maximă a unui tabel ce va fi transmis tuturor nodurilor executor atunci când are loc *join*-ul.
- Hint BROADCAST pe *table1* => transmiterea lui *table1* va avea prioritate chiar dacă dimensiunea lui table1 este mai mare decât valoarea parametrului *spark.sql.autoBroadcastJoinThreshold*
- Prioritate: *broadcast* > *merge* > *shuffle_hash* > *shuffle_hash_nl*

```
spark.table("src").join(spark.table("records").hint("broadcast"),
"key").show()
```

Strategii pentru operația de *join*

- Broadcast *join* – efectuează join-ul pe 2 relații prin:
  - *broadcast*-ul relației mai mici în toți executorii
  - Evaluarea criteriului de join cu partițiile celeilalte relații aflate pe executorul respectiv

Pandas cu Apache Arrow

- Apache Arrow este un format de date columnar, *in-memory*, utilizat de către Spark pentru a face transferul eficient al datelor între procesele JVM și Python.
- Benefic utilizatorilor Python care lucrează cu date Pandas/NumPy.
- Utilizarea nu este automată și necesită modificări în configurare sau cod.
- Pandas este o librărie open-source, cu licență BSD, ce furnizează performanță, structuri de date ușor de folosit și tool-uri de analiză a datelor pentru limbajul Python.
  - PySpark suportă Pandas

PySpark și Pandas

- PySpark poate converti date între (tipul) *DataFrame* din PySpark și *DataFrame* din Pandas
  - `pdf = df.toPandas()`
  - `df = spark.createDataFrame(pdf)`
- Putem folosi *Arrow* ca format intermediar, prin configurarea *spark.sql.execution.arrow.pyspark.enabled* = *true* (implicit este *false*)

Pandas cu Apache Arrow

- *Arrow* permite optimizarea conversiei între cele două tipuri *DataFrame*.
- Aceste optimizări pot să nu fie luate în considerare (și să aibă loc optimizări non-*Arrow*) dacă apar erori.
  - Parametrul care controlează acest lucru este *spark.sql.execution.arrow.pyspark.fallback.enabled*

Pandas cu Apache Arrow

```
import numpy as np
import pandas as pd

# Activarea transferurilor de date pe coloane bazate pe Arrow
spark.conf.set("spark.sql.execution.arrow.pyspark.enabled", "true")

# Generarea unui DataFrame Pandas
pdf = pd.DataFrame(np.random.rand(100, 3))

# Crearea unui DataFrame Spark din DataFrame-ul Pandas folosind Arrow
df = spark.createDataFrame(pdf)

# Convertirea DataFrame-ului Spark înapoi la Pandas DataFrame folosind
Arrow
result_pdf = df.select("*").toPandas()
```

Pandas cu Apache Arrow

- Prin apelul *DataFrame.toPandas*() se colectează toate înregistrările din *DataFrame* în *Driver Program* => ar trebui să se efectueze pe o submulțime a datelor
- Nu toate tipurile de date Spark sunt suportate și pot apărea erori dacă o coloană are un tip care nu este suportat
- Dacă apare o eroare în cadrul operației *SparkSession.createDataFrame()*, atunci Spark va crea *DataFrame*-ul fără *Arrow*

Funcții definite de utilizator (UDF) în Pandas

- Pandas UDFs = Vectorized UDFs
- Sunt funcții definite de utilizator ce sunt executate de către Spark folosind *Arrow* pentru transferul datelor și Pandas pentru a lucra cu datele, lucru ce permite operațiile vectorizate.
- Un UDF Pandas se definește folosind decoratorul pandas_udf() și se comportă ca orice funcție PySpark
- Python >=3.6 permite utilizarea *hint*-urilor de tipuri

Funcții definite de utilizator (UDF) în Pandas

```
import pandas as pd

from pyspark.sql.functions import pandas_udf

@pandas_udf("col1 string, col2 long")
def func(s1: pd.Series, s2: pd.Series, s3: pd.DataFrame) -> pd.DataFrame:
    s3['col2'] = s1 + s2.str.len()
    return s3

# Create a Spark DataFrame that has three columns including a struct column.
df = spark.createDataFrame(
    [[1, "a string", ("a nested string",)]],
    "long_col long, string_col string, struct_col struct<col1:string>")

df.printSchema()
# root
# |-- long_column: long (nullable = true)
# |-- string_column: string (nullable = true)
# |-- struct_column: struct (nullable = true)
# |    |-- col1: string (nullable = true)

df.select(func("long_col", "string_col", "struct_col")).printSchema()
# |-- func(long_col, string_col, struct_col): struct (nullable = true)
# |    |-- col1: string (nullable = true)
# |    |-- col2: long (nullable = true)
```

Funcții definite de utilizator (UDF) în Pandas

- Hint-ul de tip utilizează *pandas.Series* în toate cazurile, dar există un caz în care se utilizează hint-ul *pandas.DataFrame*: atunci când coloana (de intrare sau ieșire) este de tip *StructType*
- *Hint*-uri de tip suportate:
  - *pandas.Series*, … -> *pandas.Series*
  - *Iterator*[*pandas.Series*] -> *Iterator*[*pandas.Series*]
  - *Iterator*[*Tuple*[*pandas.Series*, …]] -> *Iterator*[*pandas.Series*]
  - *pandas.Series*, … -> *Any* (orice tip scalar)
  - + varianta *pandas.DataFrame*

Bibliografie

1. Apache Spark documentation (https://spark.apache.org/docs/latest).

2. Apache Spark SQL Programming Guide (http://spark.apache.org/docs/latest/sql-programming-guide.html)

3. https://docs.databricks.com/spark/latest/spark-sql/udf-python.html

4. https://spark.apache.org/docs/latest/api/python/user_guide/arrow_pandas.html

5. https://www.slideshare.net/ueshin/apache-arrow-and-pandas-udf-on-apache-spark

6. https://spark.apache.org/docs/latest/sql-ref-syntax-qry-select-window.html